

2018年10月25日

Watanebe, 6.3

@unaoya

統計的学習

1. 真の分布 $q(x)$ またはそこから生成されるサンプルを予測したい
2. モデル $p(x|w)$ とパラメータ空間 W を設定
3. 与えられたサンプルからパラメータ空間上の測度および予測分布 $\hat{p}(x)$ を決定

モデルを評価したい

Bayes quartet

四つのモデルの評価基準

	Bayes 推測	Gibbs 推測
分布	B_g	G_g
サンプル	B_t	G_t

これらはサンプル D_n に依存した確率変数

6.3の目標

- サンプル数 $n \rightarrow \infty$ における漸近挙動
- サンプルについての期待値
- これらの4つの間の関係

について調べる。

今日は G_g について

Gibbs 推測

事後分布に従ってパラメータ \hat{w} をサンプリングし、 $\hat{p}(x) = p(x|\hat{w})$ を予測分布とする。

汎化誤差 G_g

$q(x)$ と $\hat{p}(x)$ の KL divergence を w について事後分布 $p(w|\textcolor{red}{D}_n)$ で積分したもの

$$G_g = \int_{\mathcal{W}} K(w) p(w|\textcolor{red}{D}_n) dw$$

問題

$n \rightarrow \infty$ で nG_g がどのような確率変数に収束するか？

主要項

$$G_g(\epsilon) = \frac{\int_{K(w) \leq \epsilon} K(w) p(w|D_n) dw}{\int_{K(w) \leq \epsilon} p(w|D_n) dw}$$

補題 1 (Lemma 6.3). $nG_g - nG_g(\epsilon)$ は 0 に確率収束する。

主要項の評価

$$\begin{aligned} G_g(\epsilon) &= \frac{\int_{K(w) \leq \epsilon} K(w) p(w|D_n) dw}{\int_{K(w) \leq \epsilon} p(w|D_n) dw} \\ &= E[K(w) | K(w) \leq \epsilon] \end{aligned}$$

の評価をしたいが直接は難しい。

特異点解消を使う

標準形

$$f(x, g(u)) = \log\left(\frac{q(x)}{p(x|g(u))}\right) = a(x, u)u^k \text{ とし}$$

$$K(g(u)) = u^{2k}$$

$$K_n(g(u)) = u^{2k} - \frac{1}{\sqrt{n}}u^k \xi_n(u)$$

$$\xi_n(u) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \{a(X_i, u) - E_X[a(X, u)]\}$$

$\xi_n(u)$ はサンプル D_n に依存した確率過程。 ξ_n は Gauss 過程 ξ に法則収束する。

補題 2 (6.51).

$$G_g^*(\xi_n) = E_{y,t}[t|\xi_n]$$

と定義すると

$$nG_g(\epsilon) - G_g^*(\xi_n) \xrightarrow{P} 0$$

特異点解消 M 上での積分 $E_{y,t}$ と E_u

- $\xi(u)$: M 上の C^1 級関数 (サンプルの確率過程)
- $f(u)$: M 上の関数 ($K(w)$ に対し $f(u) = u^{2k}$)
- $0 \leq \sigma \leq 1$

$$E_u^\sigma[f(u)|\xi] = \frac{\sum_{\alpha \in A} \int_{[0,b]^d} f(u) Z(u, \xi) du}{\sum_{\alpha \in A} \int_{[0,b]^d} Z(u, \xi) du}$$

A は座標近傍の (有限) 集合。

$Z(u, \xi)$ は

$$u^h \phi^*(u) \exp(-\beta n u^{2k} + \beta \sqrt{n} u^k \xi(u) - \sigma u^k a(X, u))$$

事後分布 $p(w|D_n)$ との関係。

- $u^h \phi^*(u)$ が事前分布 $\phi(w)$ に対応。
- $\sigma = 0$ として

$$\begin{aligned} Z_n^0 p(w|D_n) &= \exp(-n\beta K_n(w)) \\ &= \exp(-\beta n u^{2k} + \beta \sqrt{n} u^k \xi_n(u)) \end{aligned}$$

補題 3 (6.41).

$$G_g(\epsilon) = E_u^0[u^{2k} | \xi_n]$$

$u^{2k} = K(g(u))$ **であった。**

本質的部分

座標 $u = (x, y)$ と本質的部分 $A^* \subset A$ ($K(w)$ の特異点解消から決まる)

$$E_{y,t}[f(y,t)|\xi] =$$

$$\frac{\sum_{\alpha \in A^*} \int dt \int_{[0,b]^{d-m}} f(y,t) Z_0(y,t,\xi) du}{\sum_{\alpha \in A^*} \int dt \int_{[0,b]^{d-m}} Z_0(y,t,\xi) du}$$

$$Z_0(y, t, \xi) = \gamma_b y^\mu t^{\lambda-1} \exp(-\beta t + \beta \sqrt{t} \xi_0(y)) \phi_0^*(y)$$

補題 4 (Lemma 6.6, $p = 1, f = 1, \xi = \xi_n$).

$$|E_u^0[nu^{2k}|\xi_n] - E_{y,t}[t|\xi_n]| \leq \frac{D(\xi_n, 1, \phi^*)}{\log n}$$

この証明に4章での分配関数の計算を用いる。

収束先の構成

定義 1 (6.46). M 上の関数 $\psi(u)$ に対し

$$G_g^*(\psi) = E_{y,t}[t|\psi]$$

これを使ってさっきの補題を書き直すと

補題 5.

$$|nG_g(\epsilon) - G_g^*(\xi_n)| \leq \frac{D(\xi_n, 1, \phi^*)}{\log n}$$

結論

ξ_n が ξ に法則収束することから

- 補題4を用いて $nG_g(\epsilon) - G_g^*(\xi_n) \rightarrow 0$
- $G_g^*(\xi_n) - G_g^*(\xi) \rightarrow 0$

が言える。

全て合わせて $nG_g - G_g^*(\xi) \rightarrow 0$ が証明できた。

$G_g^*(\xi)$ は ξ に依存した確率変数である。

4章の復習

ゼータ関数

開集合 $U \subset \mathbb{R}^d$ 上の非負解析的関数 $K(w)$ とコンパクト台 C^∞ 関数 $\phi(w)$ に対し、

$$\zeta(z) = \int K(w)^z \phi(w) dw$$

と定義する。この極の位置とその位数はどのような情報を持つか？

状態密度関数

$\zeta(z)$ の逆 Mellin 変換は状態密度関数

$$v(t) = \int \delta(t - K(w)) \phi(w) dw$$

である。Mellin 変換の理論により、この発散のオーダーが $\zeta(z)$ の極の位置と対応。

分配関数

状態密度関数 $v(t)$ の Laplace 変換

$$Z(n) = \int \exp(-nK(w))\phi(w)dw$$

を分配関数という。これが6章前半で調べていたもの。

特異学習理論

Remark 4.4 にあるように

$$Z = \int \exp(-n\beta K(w) + \beta \sqrt{nK(w)} \xi(w)) \phi(w) dw$$

の $n \rightarrow \infty$ での挙動を調べたい。

K についての特異点解消により、normal crossing
の場合の積分 $Z(n, \xi, \phi)$ を用いて

$$Z = \sum_{\alpha} Z(n, \xi \circ g_{\alpha}, \phi \circ g_{\alpha} |g'_{\alpha}|)$$

と書けるので、 $Z(n, \xi, \phi)$ について調べるのが 4.4
の目標。

$$Z^p(n, \xi, \phi) = \int_{[0,b]^r} dx \int_{[0,b]^s} dy K(X, y)^p x^h y^{h'} \phi(x, y) \exp(-n\beta K(x, y)^2 + \sqrt{n}\beta K(x, y)\xi(x, y))$$

と定義する。

さらにこれで $\xi = 0, \phi = 1$ と置いたものを

$$Z^p(n) = \int_{[0,b]^r} dx \int_{[0,r]^s} dy \\ K(x, y)^p x^h, y^{h'} \exp(-n\beta K(x, y)^2)$$

と書くことにする。

定理 1 (Theorem 4.7).

$$\frac{h_i + 1}{2k_i} = \lambda$$

が一定で

$$\frac{h'_j + 1}{2k'_j} > \lambda$$

とする。 $K(x, y) = x^k y^{k'}$ のときに、ある $a_1, a_2 > 0$ **が存在して任意の n に対して**

$$a_1 \frac{(\log n)^{r-1}}{n^{\lambda+p}} \leq Z^p(n) \leq a_2 \frac{(\log n)^{r-1}}{n^{\lambda+p}}$$

平均誤差関数 $K(w)$ と事前分布 $\phi(w)$ に対して
ゼータ関数

$$\zeta(z) = \int K(w)^z \phi(w) dw$$

を定義する。この極の情報から K の？特異点
の実対数閾値がもとまる。これが自由エネルギー
および汎化損失の理論値が明らかになる。

0.1 疑問点

正則な場合の計算をやる。特にこの時正則性をどこで使うか。正則な場合、サンプルが多いことが仮定される？